

## 深度学习在输电线路中部件识别与缺陷检测的研究\*

汤踊<sup>1</sup> 韩军<sup>1</sup> 魏文力<sup>2</sup> 丁建<sup>2</sup> 彭新俊<sup>1</sup>

(1. 上海大学通信与信息工程学院 上海 200444; 2. 国网浙江省电力公司检修分公司 杭州 310007)

**摘要:** 输电线路稳定运行是保障电力系统安全的重要环节之一,经典的机器学习算法对输电线路部件识别与分类准确率和效率都比较低。针对这一问题,选取了具有识别与分类功能的区域卷积神经网络(Faster-RCNN)来对部件进行识别与分类,研究了不同网络模型在输电线路中对不同部件的识别准确率和识别时间,结合实验结果,根据识别准确率和识别时间的优劣选取最佳网络模型,然后就如何提高模型的识别准确率和缩短识别时间展开研究,提出两种方法:通过调整CNN模型的卷积核大小和图像的旋转变换扩充数据集,实验结果表明两种方法都能有效的提高了输电线路巡检中的部件识别与缺陷检测的有效性和可靠性。利用无人机实际采集的图像进行识别和分类实验,实验结果表明深度学习方法在高压输电线路部件的识别与缺陷检测中的有效性和可靠性都非常高,Faster R-CNN进行部件识别与缺陷检测可以达到每张近0.17s的识别速度,对均压环的识别率最高可达到96.8%,mAP最高可以达到93.72%。

**关键词:** Faster-RCNN;网络模型;深度学习;有效性;可靠性

**中图分类号:** TP391.4;TN081 **文献标识码:** A **国家标准学科分类代码:** 510.1050

## Research on part recognition and defect detection of transmission line in deep learning

Tang Yong<sup>1</sup> Han Jun<sup>1</sup> Wei Wenli<sup>2</sup> Ding Jian<sup>2</sup> Peng Xinjun<sup>1</sup>

(1. School of Communication and Information Engineering, Shanghai University, Shanghai 200444, China;

2. State Grid Zhejiang Electric Power Company Maintenance Branch, Hangzhou 310007, China)

**Abstract:** The stable operation of the transmission line is one of the important parts to ensure the safety of the power system. The classical machine learning algorithm has low accuracy and efficiency in the recognition and classification of transmission line components. Aiming at this problem, this paper selects the Region-based convolutional neural network (Faster-RCNN) to identify and classify the components, different network model in the transmission line is studied in the different components of recognition accuracy and recognition time, combined with the experimental results, according to the merits of the recognition accuracy and recognition time to select the best network model, and then how to improve the accuracy of the model recognition and shorten the recognition time to start research, this paper proposed two methods - by adjusting the kernel size of CNN model and image rotation transformation to expand the data set, the experimental results show that both methods can effectively improve the validity and reliability of component recognition and defect detection in transmission line inspection. Using the images by Unmanned Aerial Vehicle (UAV) collected to conduct recognition and classification experiment, the experimental results show that the validity and reliability of deep learning approach in identifying and defect detection of high voltage transmission line components is very high, and Faster R-CNN is used to identify and defect the parts, The detection rate can reach the recognition rate of nearly 0.17s, the recognition rate of the equalization ring can be up to 96.8%, and the maximum mAP can reach 93.72%.

**Keywords:** Faster-RCNN; network model; deep learning; effectiveness; reliability

收稿日期:2017-11

\* 基金项目:国家自然科学基金(61471230)项目资助

• 60 •

## 0 引 言

为提高输电线路的巡检与维护效率,我国国家电网现已采用比较普及的无人机(unmanned aerial vehicle, UAV)巡检方式<sup>[1]</sup>对输电线路进行巡检。无人机巡检虽然降低了劳动成本和野外作业的风险。但是,无人机巡检会产生海量的图像数据用于人工分析输电线路及其部件是否出现故障,这一工作量十分巨大,因此,研究一种可扩展性的智能缺陷识别与分类技术用于输电线路部件的缺陷检测与分类具有非常重要的意义。

输电线路部件主要有以下几个类别:均压环,间隔棒,绝缘子、防震锤、导线等,无人机巡检主要是对这些部件进行图像采集,得到的图像是三维的且具有图像背景比较复杂、部件与背景的对比度比较低、存在大量干扰等一系列问题。最初的图像识别算法主要集中在针对目标的形状(边缘、轮廓)和纹理特征进行提取识别。如对于防震锤,可利用 Hough 变换检测防震锤的圆形部分<sup>[2]</sup>;也可以提取边缘图像中某些图形基元并施加结构约束<sup>[3]</sup>;利用层次模型“与或图”对目标进行分解表达<sup>[4]</sup>;从而实现对防震锤的检测。利用边缘检测方法实现对绝缘子的检测<sup>[5]</sup>。基于可见光图像识别间隔棒框架断裂故障<sup>[6]</sup>。利用局部轮廓特征的形状来检测导线上的断股与异物缺陷<sup>[7]</sup>。利用图像的灰度共生矩阵纹理特征对导线进行提取<sup>[8]</sup>。以上这些方法在一定程度上虽然能够达到最终的检测目的,但只能局限在具体某一类别之中,并且在实际应用之中,受到成像条件、外界环境和对光照的变化影响,会产生灰度畸变和图像噪声,导致对目标检测的有效性和可靠性都不够理想,且不具有扩展性。

随后利用机器学习的方法识别输电线路部件成为热点。利用目标建议算法与结构搜索对绝缘子进行识别定位<sup>[9]</sup>。利用类 Haar 特征与级联 Ada Boost 算法识别防震锤<sup>[10]</sup>。利用障碍物边缘图像的小波矩与联合不变矩作为特征值,结合小波神经网络对障碍物进行识别与分类<sup>[11]</sup>。利用支持向量机(SVM)算法实现对高压输电线路故障的识别与分类<sup>[12]</sup>。上述机器学习方法相对于最初的图像识别算法,在一定程度上,提高了可靠性,但是在识别的准确率和识别时间上,仍然有很大的提升空间,并且这些方法并不会随着样本数量的增加而提高其准确率。

近年来,深度学习在图像识别与检测这一领域取得了非常好的成果。典型的 R-CNN 目标识别方案在 2014 年由 Girshick 等人<sup>[13]</sup>提出,但其精确率和识别时间都不理想。随后在 R-CNN 基础上进行改进,依次提出了 Fast-RCNN 方案<sup>[14]</sup>和 Faster-RCNN<sup>[15]</sup>方案。目前 Faster-RCNN 方案在图像识别与分类这一领域的精确度最高。文献<sup>[16]</sup>提出了利用 Faster-RCNN 识别输电线路部件,分析了不同的参数对间隔棒、防震锤和均压环 3 类部件的识别准确率和效率的影响,但并未对部件的缺陷进行识别定位,且其样本图

片通过截图获取,在一定程度上丢失了样本原信息。本文针对输电电路部件识别与缺陷检测这一特定场景,采用 Faster-RCNN 网络结构,研究了不同网络模型在输电线路中对不同部件的识别准确率和识别时间,结合实验结果,根据识别准确率和识别时间的优劣选取最佳网络模型,然后就如何提高模型的识别准确率和缩短识别时间展开研究,本文共提出两种方法——通过图像的旋转变换扩充数据集和调整 CNN 模型的卷积核大小,实验结果表明两种方法都有效的提高了输电线路巡检中的部件识别与缺陷检测的有效性和可靠性。

## 1 Faster-RCNN 的电力部件识别研究

Faster-RCNN<sup>[15]</sup>对目标的识别检测过程主要分为如下 4 个步骤:1)首先使用一组基础的 CNN(convolution neural network)网络提取输入图片的特征块,该特征块被后续的 RPN(region proposal network)网络和 Fast-RCNN 网络共享。2)RPN 网络用于生成提议区域,通过分类函数判断提议区域属于目标区域还是背景,然后利用边框回归(regression)函数修正提议区域,使其获得更加精确的提议区域。3)ROI(region of interest)层收集输入的特征块和修正后的提议区域,综合这些信息提取出统一大小的提议特征块,然后将提议特征块输入最后的全连接层。4)全连接层和分类函数利用输入进来的 ROI 特征向量计算提议区域的类别,同时再次利用边框回归函数获得检测框最终的精确位置。整个识别流程如图 1 所示。

其中 feature map 表示经过 CNN 网络提取后的特征块;conv 表示卷积;SoftMax 表示分类函数;Regression 表示边框回归函数;Proposals 表示区域提议层;ROI pooling 表示 ROI 池化层;fc(full connected layer)代表全连接层,relu(rectified linear units)代表激活层。

对于步骤 1),从图 1 可以看到,对于任意一副大小为  $P \times Q$  的图像,先将其输入至 CNN 网络,经过一系列的卷积层、激活层、池化层最终可得到被后续 RPN 网络和 Faster-RCNN 网络共享的特征块。

然而对于每一个卷积神经网络模型来说,它的网络结构都不一样。本文选取 ZF 网络模型<sup>[17]</sup>、VGG16 网络模型<sup>[18]</sup>和 ResNet-101 网络模型<sup>[19]</sup>作为实验对象,其中其中 ZF 模型的网络结构为 5 层卷积层,7 层激活层、3 层池化层和 3 层全连接层。VGG16 模型的网络结构为 13 层卷积层、15 层激活层、5 层池化层、3 层全连接层。ResNet-101 模型的网络层数更深,多达 100 多层卷积层,且采用残差结构进行特征提取。那么这 3 种网络结构对于同一张图片所提取出来的特征肯定会不一样,因此这 3 种模型的识别准确率和识别时间肯定不一样。其次对于卷积层来说,不同的卷积核大小在进行卷积时所得到的参数也不一样,设卷积核大小为  $n$ ,偏置参数为 1,提取的特征块个数为  $x$ ,那么卷积后得到的参数个数就为  $(n \times n + 1) \times x$ 。另外不同的

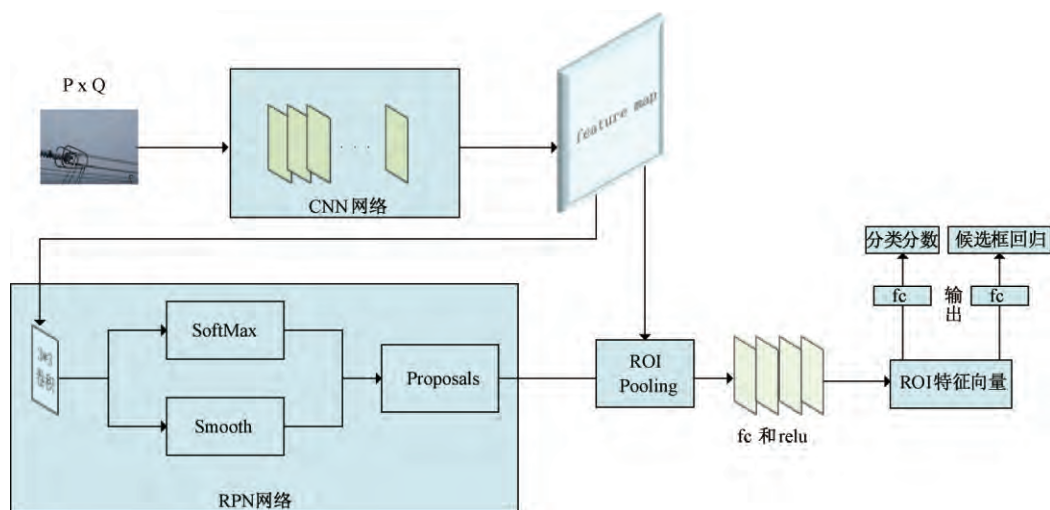


图 1 Faster-RCNN 识别流程

卷积核大小在进行卷积时对于图片感受野来说也不一样,参数个数不同会对识别时间产生影响,卷积时对图片的感受野不同也会对识别准确率产生影响。最后根据 Faster-RCNN 的特征——增加训练数据来提升模型的泛化能力,因此本文在实验部分提出了通过对图片的旋转变换方法来扩充训练数据集,并且通过实验来验证此方法是否能提高模型的泛化能力,从而优化测试结果。

依据以上思路,本文共分为 3 个部分,第 1 部分是数据集处理和模型训练,介绍了数据集的来源与处理方法,然后介绍了模型训练时的一些参数。第 2 部分是实验结果与分析,总共分为 3 个实验,1)研究 ZF 网络模型、VGG16 网络模型和 ResNet-101 网络模型在输电线路中对不同部件的识别准确率和识别时间,2)研究不同的卷积核大小对识别准确率和识别时间的影响,3)研究通过旋转变换方法扩充数据

集能否优化识别准确率和识别时间。第 3 部分是总结部分,主要是对整个实验部分进行归纳性总结,并结合实验结果提出一些优化识别准确率的设想。

## 2 数据集与模型训练

### 2.1 数据集准备

本文数据集主要来源于无人机巡检时所拍摄的图片,图片在季节上涵盖了春、夏、秋、冬 4 个季节,拍摄地点多样化,且无人机采集的图片具有很高的分辨率。本文针对输电线路部件识别与缺陷诊断问题,主要选用均压环 1、均压环 2、完好的防震锤、坏的防震锤、鸟窝共 5 种不同类别的部件作为模型训练样本,样本如图 2 所示。其中模型训练样本中每一类别 1 000 张,共 5 000 张训练样本,每张样本图片大小为  $6\,000 \times 4\,000$ 。



图 2 训练样本

### 2.2 数据集处理

首先将训练样本统一缩放至  $1\,200 \times 800$ ,然后对于训练集中每一张图片出现的完整的电力部件目标,标记其外围框,并将外围框坐标位置进行记录,并给定类别标签。

对于测试样本,每一类选用 500 张图片作为测试集,测试集中绝不包含训练样本。对于测试集,在进行识别与分类时,要标记出每张图片里出现的所有的包含在训练样本之中的电力部件,包括不完整的和被遮挡的,并给出类别标签和分数,至此将其视为一次成功的识别。

### 2.3 模型训练

本文是基于 MXNET 框架,采用 Faster-RCNN 实现网络模型的训练,依次采用 ZF 网络、VGG16 网络、ResNet-101 网络对预训练的 ImageNet 网络进行初始化,得到 3 个不同网络层数的模型。使用 2.2 节中的数据集作为训练样本。对于每一次的模型训练,训练次数均为 20 次,批尺寸大小为 128,学习率为 0.001,权重衰减率为 0.000 5,非极大值抑制前后候选区域个数分别为 6 000 和 300。本次实验采用正确率、召回率和漏识别率作为模型好坏的评判标准,其中正确率表示识别正确的目标数与所

有识别出来的目标数的比值;召回率表示识别正确的目标数与所有样本目标数的比值;漏识别率表示未识别出来的目标数与所有样本目标数的比值。

### 3 实验结果与分析

#### 3.1 模型的识别效果对比

实验采用 2.2 节中的测试集作为 3 种不同模型的测试

集,采用 2.3 节中训练所得到的 3 种模型作为测试模型,采用准确率、召回率和漏识别率作为模型好坏的评判标准。3 种模型在输电线路部件识别的应用中,识别效果如表 1~3 所示。

根据表 1~3 的实验结果可以得到在 3 个不同模型下被检测的 5 类目标的召回率、正确率和漏识别率的大小,对于召回率来说,ResNet-101 模型的召回率最高,其次是

表 1 ZF 模型验证结果

类别	验证集/张	正确识别/张	错误识别/张	漏识别/张	召回率	正确率	漏失别率
均压环 1	500	422	8	70	0.844	0.981	0.140
均压环 2	500	411	6	83	0.822	0.986	0.166
鸟窝	500	408	2	90	0.816	0.995	0.180
好的防震锤	500	380	10	110	0.760	0.974	0.220
坏的防震锤	500	366	12	122	0.732	0.968	0.244
mAP					0.795	0.981	0.190

表 2 VGG16 模型验证结果

类别	验证集/张	正确识别/张	错误识别/张	漏识别/张	召回率	正确率	漏失别率
均压环 1	500	438	5	57	0.876	0.989	0.114
均压环 2	500	439	3	58	0.878	0.993	0.116
鸟窝	500	431	0	69	0.86	1	0.138
好的防震锤	500	409	1	90	0.818	0.998	0.180
坏的防震锤	500	395	3	102	0.79	0.992	0.204
mAP					0.795	0.994	0.150

表 3 ResNet-101 模型验证结果

类别	验证集/张	正确识别/张	错误识别/张	漏识别/张	召回率	正确率	漏失别率
均压环 1	500	458	1	41	0.916	0.998	0.082
均压环 2	500	457	1	42	0.914	0.998	0.084
鸟窝	500	453	0	47	0.906	1	0.094
好的防震锤	500	426	1	73	0.852	0.998	0.146
坏的防震锤	500	412	2	86	0.824	0.995	0.170
mAP					0.882	0.998	0.115

VGG16 模型,最后是 ZF 模型;对于正确率来说,ResNet-101 模型最优,其次是 VGG16 模型,最后是 ZF 模型;对于漏识别率来说,ResNet-101 模型的漏识别率最低,VGG16 模型的漏识别率要低于 ZF 模型;所以很容易得到:对于输电线路部件识别与检测来说 ResNet-101 模型优于其他两个模型。其中 ResNet-101 模型的检测效果如图 3 所示。从表 1~3

可以看到对于均压环 1、均压环 2、鸟窝的识别效果都远超于对防震锤的识别效果。原因可能如下:1)防震锤结构特征不够明显;2)防震锤训练样本数据不够充分,导致模型对其泛化能力不够好。从表 4 可以看到 ResNet-101 模型、VGG16 模型和 ZF 模型对于一张图片的计算时间,其中 ResNet-101 模型对于单张图片的识别时间最大。



图 3 检测效果

表 4 3 种模型的识别时间

模型	ZF 模型	VGG16 模型	RESNET-101
识别时间/(ms/张)	73	101	178

### 3.2 卷积核大小对识别效果的影响

根据表 1~3 的实验结果,针对防震锤识别效果不理想和单张图片识别时间优化问题,选取最优模型 ResNet-101 模型进行实验,实验方向是对其卷积结构的卷积核进行修改,主要是针对第 1 层卷积核大小进行修改。根据第 1 节中的内容可以得知不同的卷积核大小对识别准确率和识别时间都会有影响。

ResNet101 模型网络第 1 层卷积层中卷积核大小为 7,根据实验思路,逐步降低卷积核大小进行模型训练,参数设置与 2.3 节中的参数设置一致,然后用训练好的模型对样本进行检测,以召回率和识别时间作为实验指标;所有样本数量均为 500 张,实验结果如表 5 所示。

表 5 不同卷积核大小的召回率

卷积	均压环 1	均压环 2	鸟窝	好的防震锤	坏的防震锤
9*9	0.928	0.921	0.914	0.868	0.834
7*7	0.916	0.914	0.906	0.852	0.824
5*5	0.902	0.901	0.891	0.838	0.811
3*3	0.889	0.885	0.879	0.824	0.801
1*1	0.872	0.870	0.868	0.818	0.788

根据实验结果可以看到,不同的卷积核大小对检测的

准确率是有影响的,并且可以得到,随着卷积核大小的减小,召回率也不断降低,这是因为大的卷积核其感受野也大,感受野大的卷积核其识别准确率也高。根据表 6 可知,随着卷积核大小的降低,对单张图片的识别时间也随之降低,这是因为不同的卷积核大小它识别时所得到的参数数量也不一样,卷积核小的得到的参数数量少,卷积核大的得到的参数数量多。因此可以通过调整卷积核大小来优化模型,满足自己的实际需求——需要较高的召回率还是较低的识别时间。

表 6 ZF 不同卷积核大小对单张图片的识别时间

卷积	9*9	7*7	5*5	3*3	1*1
识别时间/(ms/张)	185.3	178.2	168.4	161.2	154.8

### 3.3 旋转变换扩充数据集

本次实验主要是将 2.2 节中的训练集中的 5 种不同部件的图像分别做了 90°、180°、270°旋转,共得到 20 000 张训练样本,扩大了训练样本集,然后以此训练样本集作为 ResNet-101 模型的训练样本,对模型进行训练,训练参数设置与 2.3 节中的参数设置一致,然后用训练得到的模型对 2.2 节中测试集进行测试,测试结果如表 7 所示。

根据表 7 的实验结果可以得到,利用扩充后的数据集进行模型训练得到的训练模型,利用此训练模型进行识别的任何一个类别的召回率都优于扩充前的召回率,正确率和漏识别率也比扩充前要好,因此可以得到,通过旋转变换的方法来扩充数据集,可以提高识别准确率。

表 7 数据扩充后 ResNet-101 模型验证结果

类型	验证集/张	正确识别/张	错误识别/张	漏识别/张	召回率	正确率	漏失别率
均压环 1	500	484	1	15	0.968	0.998	0.030
均压环 2	500	482	1	17	0.964	0.998	0.034
鸟窝	500	479	0	21	0.958	1	0.042
好的防震锤	500	453	1	46	0.906	0.998	0.092
坏的防震锤	500	449	2	49	0.890	0.996	0.098
mAP					0.882	0.998	0.115

本文所有实验均在同一台机器上进行,识别时间是使用 Nvidia Quadro m4000 GPU(8G 显存)计算出来的。

## 4 结 论

本文针对输电线路部件识别与缺陷检测这一特定场景,采用 Faster-RCNN 网络结构,主要研究了不同网络模型检测结果的召回率和时间,根据实验结果可以得到,在召回率上,ResNet-101 模型的召回率最高,其次是 VGG16 模型,最后是 ZF 模型。但是在单张图片的识别时间上,ResNet-101 模型所花费时间最多,VGG16 模型次之,ZF 模型所花费时间最少,表 4 实验结果证明了较高的

召回率是通过牺牲时间来获取的。随后研究了不同卷积核大小对识别准确率和识别时间的影响,通过实验可以得到,召回率和单张图片的识别时间都随卷积核的减小而减小,因此可以通过调整卷积核的大小来优化模型,满足自己的实际需要,最后提出了通过旋转

变换来扩充训练集的方法,通过实验证明,此方法能够提高识别准确率。

本文实验结果表明,深度学习在输电线路中的部件识别与缺陷检测中可以得到很好的应用,可为后期的无人机巡检图像的智能化处理奠定良好的基础。此外,针对无人机航拍图像训练集不足的问题,可依据本文中的旋转变化

扩充数据集的方法为参考,通过图像切割、图像白化等数据增强方式来进行数据集扩充,从而提高识别准确率。

#### 参考文献

- [1] 汤明文,戴礼豪,林朝辉,等. 无人机在电力线路巡视中的应用[J]. 中国电力,2013,46(3):35-38.
- [2] 陈晓娟,吴英石,赵亮. 基于随机 Hough 变换的 OPGW 防震锤识别[J]. 黑龙江电力,2010,32(1):1-2,5.
- [3] 胡彩石,吴功平,曹珩,等. 高压输电线路巡线机器人障碍物视觉检测识别研究[J]. 传感技术学报,2008,21(12):2092-2096.
- [4] 付晶,邵瑰玮,吴亮,等. 利用层次模型进行训练学习的线路设备缺陷检测方法[J]. 高电压技术,2017,43(1):266-275.
- [5] 王伟,刘国海. 绝缘子图像的边缘检测[J]. 微计算机信息,2008(27):308-309,154.
- [6] 金立军,胡娟,闫书佳. 基于图像的高压输电线间隔棒故障诊断方法[J]. 高电压技术,2013,39(5):1040-1045.
- [7] 王万国,张晶晶,韩军,等. 基于无人机图像的输电线断股与异物缺陷检测方法[J]. 计算机应用,2015,35(8):2404-2408.
- [8] 赵建坤,王璋奇,刘世钊. 基于灰度共生矩阵纹理特征的输电导线识别[J]. 云南电力技术,2015,43(2):126-129.
- [9] 翟永杰,王迪,赵振兵. 基于目标建议与结构搜索的绝缘子识别方法[J]. 华北电力大学学报(自然科学版),2016,43(4):66-71,78.
- [10] 金立军,闫书佳,刘源. 基于类 Haar 特征与级联 AdaBoost 算法的防震锤识别[J]. 系统仿真学报,2012,24(9):1806-1809.
- [11] 曹文明,王耀南,印峰,等. 高压输电线路除冰机器人障碍物识别方法研究[J]. 仪器仪表学报,2011,32(9):2049-2056.
- [12] 姜惠兰,崔虎宝,刘飞,等. 基于模糊逻辑和支持向量机的高压输电线路故障分类器[J]. 中国电力,2005(3):13-17.
- [13] GIRSHICK R, DONAHUE J, DARRELL T, MALIK J. Region-Based Convolutional Networks for accurate object detection and segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2015, 38(1):142-158.
- [14] GIRSHICK R. Fast R-CNN[C]. IEEE International Conference on Computer Vision, 2015:1440-1448.
- [15] REN S, HE K, GIRSHICK R, SUN J. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(6):1137-1149.
- [16] 王万国,田兵,刘越,等. 基于 RCNN 的无人机巡检图像电力小部件识别研究[J]. 地球信息科学学报,2017,19(2):256-263.
- [17] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks[C]. European Conference on Computer Vision, 2014:818-833.
- [18] SIMONVAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. Computer Science, 2014,arXiv:1409.1556.
- [19] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]. Computer Vision and Pattern Recognition, IEEE, 2016:770-778.

#### 作者简介

汤踊,工学硕士,主要研究方向为图像处理、深度学习。

E-mail:ty1114009817@163.com