

# 深度学习用于遥感图像处理的研究进展

罗仙仙<sup>1,2,3</sup>, 曾蔚<sup>1,2,3</sup>, 陈小瑜<sup>4</sup>, 张东水<sup>5</sup>, 庄世芳<sup>1,2,3</sup>

(1.泉州师范学院 数学与计算机科学学院,福建 泉州 362000;

2.福建省大数据管理新技术与知识工程重点实验室,福建 泉州 362000;

3.智能计算与信息处理福建省高等学校重点实验,福建 泉州 362000;

4.泉州师范学院 资源与环境科学学院,福建 泉州 362000;

5.湖南科技大学 资源环境与安全工程学院,湖南 湘潭 411201)

**摘 要:**深度学习是当前机器学习与人工智能研究热点,深度学习用于遥感图像处理取得快速发展.首先简要介绍现有遥感数据源及其非监督与监督分类方法.在总结深度学习典型方法及其最新演化模型基础上,分析了深度信念网络、卷积神经网络、自动编码器在遥感图像处理中的国内外研究现状.针对当前应用现状与存在问题,指出今后研究方向:一方面要适应智能化遥感图像处理的发展趋势,加强算法理论研究,尤其人机协同工作、典型方法应用与修正、新模型拓展与应用;另一方面针对遥感大数据的应用需求,应加强遥感数据集建设、构建行业统一遥感大数据监测平台.

**关键词:**遥感;深度学习;图像处理

中图分类号:TP391

文献标识码:A

文章编号:1009-8224(2017)06-0035-07

DOI:10.16125/j.cnki.1009-8224.2017.06.008

21 世纪以来,以对地观测技术为核心的空间地球信息科技已经成为一个国家科技水平、经济实力和国家安全保障能力的综合体现<sup>[1]</sup>.遥感,作为采集地球数据及其变化信息的重要手段,被广泛应用于全球气候变化研究、航空航天、军事指挥、环境监测和国土资源调查等领域,遥感数据源向高光谱分辨率、高空间分辨率和高时间分辨率的方向发展.遥感技术的快速发展与广泛应用,使得遥感大数据逐步成为研究自然环境与社会经济的重要技术途径,已成为智慧城市发展的重要支撑.目前,影响遥感图像处理结果主要有两个影响因素:一是遥感数据源的质量,二是遥感图像处理方法,包括遥感图像预处理与分类方法.综合提取多种遥感影像特征并提高计算机自动解译精度,是遥感图像自动解译的一个发展方向.

深度学习是人工智能研究的一个重要分支,由加拿大多伦多大学 Hinton 教授于 2006 年提出的一种有效的特征提取及分类方法<sup>[2]</sup>,被应用到语音识别、图像识别、计算机视觉等领域,并取得了良好的效果.Google、Facebook、微软、百度、腾讯以及其他创业公司都在使用深度学习做到顶级的智能识别实用精度.深度学习能够自动进行特征提取,越来越多应用遥感领域.本文总结深度学习用于遥感图像处理中的研究成果,指出当前研究存在问题,展望今后发展趋势,以期拓展深度学习在不同行业遥感应用提供参考.

## 1 遥感数据源及其分类方法

### 1.1 遥感数据源

遥感影像记录的是观测区在某一时间内地物的电磁波辐射,其亮度值反映了地物的辐射光谱能量的特征,其纹理特征反映了地物的光谱结构特征<sup>[3]</sup>.目前,常用的遥感卫星影像数据有 Landsat、Spot、

收稿日期:2017-09-15

作者简介:罗仙仙(1979—),男,福建清流人,博士,副教授,从事遥感图像处理、机器学习、智能识别等研究.

基金项目:泉州市科技计划项目(2016N057);国家级和各部委项目预研基金(2016YYKJ14);福建省教育厅科研 A 类项目(JA13270);王宽诚德意志学术交流中心博士后奖学金(91551268)

NOAA、Quickbird、IKONOS、ASTER 等.不同类型的遥感影像数据具有不同的空间分辨率、光谱分辨率、辐射分辨率、时间分辨率,其信息提取精度也就不同,从而适应于不同的研究尺度及不同的研究领域.如 NOAA 气象卫星,其空间分辨率低,但实时性强,因而常用于洲级或全球范围尺度的土地利用/土地覆盖、海洋的遥感变化研究;而 Landsat 卫星系列影像,其最低空间分辨率为 30 m,在中尺度的资源环境、生态效益等的综合调查及监测,具有明显的经济与技术优势.

## 1.2 遥感图像分类方法

1.2.1 非监督分类 非监督分类又称边学习边分类,它的前提是假定遥感影像上同类物体在同样条件下具有相同的光谱信息特征.非监督分类不必对影像地物获取先验知识,仅依靠影像上不同种类的地物光谱信息特征进行特征提取,再统计特征的差别来达到分类的目的,最后对已分出的各个类别的实际属性进行确认<sup>[4]</sup>.非监督分类方法有:K 均值、ISODATA 方法等.研究者对非监督分类产生的类别较难控制,并不一定是研究者想要的,因而还必须与想要的类别匹配,结果不一定理想.

1.2.2 监督分类 监督分类是一种常用的精度较高的统计判别分类,又称为训练区分类.监督分类是先选择具有代表性的典型训练区,用从训练区中获取的地物样本的光谱特征来选择特征参数、确定判别函数或判别规则,从而把影像中的各个像元划归到各个给定类的分类方法<sup>[3-4]</sup>.这种方法要求对所要分类的地区必须要有先验的类别知识,即先要从所研究地区中选择出所有要区分的各类地物的训练区,用于建立判别函数.常用的监督分类方法有:K 近邻法、马氏距离分类、最大似然法等方法.

## 2 深度学习典型方法、演化模型与经典遥感数据集

深度学习通常是指超过三层的神经网络模型<sup>[5]</sup>,模仿人类大脑的层次结构,是一组尝试通过使用体系结构的多个非线性变换组成模型中数据的高级抽象机器学习算法.在深度学习结构中,每个中间层的输出可以视为原始输入数据的表征.每一层使用由前一层生成的表征作为输入,并生成新的表征作为输出,然后传到更高的层.底层的输入是原始数据,最后一层的输出为最终的低维特征.这一特征学习的过程是从低层到高层特征自动的提取.

深度学习典型方法包括限制玻尔兹曼机(restricted Boltzmann machines, RBM)、深度信念网络(deep belief network, DBN)、卷积神经网络(convolution neural network, CNN)和自动编码器(auto encoder, AE)等<sup>[6]</sup>.新型深度学习方法包括递归神经网络(recurrent neural network, RNN)及其变种模型长短时记忆模型(long short-term memory, LSTM)、生成对抗网络(generative adversarial nets, GAN)等. RNN 中具有反馈机制,每层神经元的输入包括前一层神经元的输出、自身在上一时间点的输出,使得 RNN 对序列数据具有较好处理能力,被广泛应用于语音识别、自然语言处理等. GAN 由 Goodfellow 等提出. GAN 同时训练两个相互对抗的模型,一个是生成模型 G,另一个是判别模型 D.生成模型 G 负责生成服从真实样本分布的假样本,判别模型 D 负责对输入的样本进行二分类判别,即尽量正确识别出是真实样本还是假样本. GAN 的训练过程是一个极大极小博弈问题,在训练过程中,固定其中一个模型,更新另一个模型的权重,双方不断优化,从而形成对抗关系,直至达成纳什均衡.目前, GAN 主要应用于图像、语音及语言生成.

### 2.1 深度信念网络

限制玻尔兹曼机是一种典型神经网络,具有两层结构,一层为可视层,另一层为隐层.可视层是数据输入层,隐层是特征提取层.层间全连接,层内无连接<sup>[7]</sup>.预训练采用无监督贪心逐层方式来获取生成性权值,使用梯度下降的方法训练避免局部最小的情况,如对比散度、连续对比散度算法等.

深度信念网络通过多层的 RBM 和一层分类器组成.其训练过程分为两步.第一步是对 DBN 进行网络预训练,即自下而上对每层的 RBM 进行无监督学习.第二步是网络微调,即自上向下的监督学习.此时使用的训练集是有标签的训练集,训练算法是标准的误差反向传播算法.对无监督学习阶段得到的特征信息进行总结、归纳、取舍,最后达到一个较好的识别水平.

### 2.2 卷积神经网络

卷积神经网络是当前应用较为广泛一种,其低隐含层由卷积层、池化层(降采样层)交替组成,高层

通常由全连接层作为分类器使用<sup>[8]</sup>。卷积层进行线性操作,负责特征提取,通常为组合卷积,其参数包括卷积核数量、核尺寸、步长、填充方式等;卷积层后加一个激活函数,通常是非线性激活函数,如 Sigmoid、Tanh、ReLU,进行非线性操作,减轻梯度消失问题;池化层在于减少特征图尺寸规模,增强特征对于旋转和变形的鲁棒性;全连接层全负责推断与分类。

卷积神经网络不断改进与优化,演化模型分别是 CaffeNet、AlexNet、VGG、GoogleNet、ResNet、ResNeXt,CNN 进化网络比较见表 1。从表可知,采取技术不断优化,网络深度扩大,Top-5 错误率在减少。

表 1 CNN 进化网络比较  
Tab.1 Comparison among evolutionary networks of CNN

进化网络	网络深度	卷积层数	全连接层数	Top-5 错误率/%	ImageNet ILSVRC 竞赛时间	主要技术
AlexNet	8	5	3	16.40	2012 年第一	ReLU、最大池化、随机失活、局部响应归一化
VGG	19	16	3	7.30	2014 年第二	核分解、随机失活
GoogleNet (V1)	22	21	1	6.70	2014 年第一	Inception V1:取消全连接层、2 个辅助分类器 Inception V2:批归一化 Inception V3:非对称卷积、取消浅层的辅助分类器
ResNet	152	151	1	3.57	2015 年	批归一化

近年来,以卷积神经网络为基础拓展的网络不断改进与优化。2014 年,Ross 等提出的区域卷积神经网络(region-based CNN,R-CNN)<sup>[9]</sup>用于图像检测,主要使用选择性搜索方法生成大量候选区域,便于后续高维特征形成,但训练时间长。空间金字塔网络(spatial pyramid pooling networks,SPP-Net)对此进行 2 大改进,一是引入空间金字塔池化层,二是放宽输入图像尺寸限制,所有区域共享卷积计算,但 SPP-Net 需要存储大量特征和复杂的多阶段训练。在 SPP-Net 基础上,2015 年 Ross 等提出了 Fast R-CNN<sup>[10]</sup>,引入 2 个新技术,一是感兴趣区域池化层,二是多任务损失函数。同年,Ren 等提出 Faster R-CNN<sup>[11]</sup>,用区域提议网络(regional proposal network)取代选择性搜索方法,解决了计算区域提议时间开销大的瓶颈问题。

2015 年,Long 等提出的用于图像语义分割的全卷积神经网络(fully convolutional neural networks,FCN)<sup>[12]</sup>,该网络所有层都是卷积层,并采取反卷积/逆卷积/去卷积(Deconvolution)操作,将低分辨率图片进行上采样,生成同分辨率的分割图片。2016 年,Dai 等提出区域全卷积神经网络(R-FCN)<sup>[13]</sup>。

2.3 自动编码器

自动编码器由编码器和解码器两部分组成。编码器将输入数据映射到特征空间,解码器将特征映射回数据空间,完成对输入数据的重建。自动编码器演化模型包括栈式自动编码器、去噪自动编码器、稀疏自动编码器、收缩自动编码器等。

2.4 典型遥感数据集

当前,深度学习用于遥感图像处理中的典型数据集见表 1,多数为高光谱遥感数据集,最常用的为印第安纳西北部的印第安纳农场数据集和意大利帕维亚大学数据集。在数据集中,多数在美国,我国数据集建设尚处空白。同时,由于深度学习方法训练与测试需要大量样本数据,实际应用微乎其微。

表 2 典型遥感数据集  
Tab.2 Typical data sets of remote sensing

类型	波谱范围/ $\mu\text{m}$	波段数	物体类别数	像素大小	空间分辨率/m
美国印第安纳州印第安纳农场(Indian Pines)	0.4~2.5	224	16	144×144	20
意大利帕维亚大学(University of Pavia)	0.43~0.86	115	9	610×340	3.7
美国加州大学默塞德分校(UC Merced)	/	/	21	256×256	0.3
美国加州萨利纳斯谷(Salinas)	/	220	19	512×217	1.3
美国佛罗里达州的混合植被图(KSC)	0.4~0.25	224	13	512×614	18

### 3 深度学习在遥感图像处理中的应用现状

深度学习能从原始数据自动进行特征学习,通过多层非线性网络逼近复杂分类问题,从海量的大数据中寻找和发现图像目标的内部结构和关系.深度学习应用于遥感图像处理尚处于起步阶段,用于高分辨率遥感与高光谱遥感影像居多,少数用于无人机;应用方法集中在 DBN、CNN、SAE.

#### 3.1 深度信念网络在遥感图像处理中的应用现状

目前深度信念网络应用遥感数据主要有高光谱遥感、合成孔径侧视雷达、高分辨率遥感,但主要是经典数据集,需要进一步拓展不同遥感数据应用、不同行业应用.从网络参数看,最优隐藏层数集中于 2~3 层,且 3 层较多.受输入与输出大小影响,各隐藏层的节点数差异较大,幅度在 50~500 之间,部份研究尚未探讨节点数对分类精度影响;绝大多数学习率是 0.01 和 0.1.从分类结果看,多数分类精度达到 90% 以上,大大超出常规目视解译、专家检验和多次纠正分类结果.

从具体应用层面看,吕启等首次利用深度信念网络应用于极化合成孔径雷达图像(Radarsat-2)分类中,当层数为 3、各隐含层节点数为 64 时,总体分类精度最高,达到 77%,好于支持向量机与传统神经网络方法<sup>[14]</sup>.陈雨时等<sup>[15]</sup>首次利用深度信念网络方法进行高光谱遥感图像特征提取,顶层采取逻辑回归的分类方法,研究提出纯光谱特征、空间特征、谱域-空域特征高光谱数据分类方法,研究提出的 DBN-LR 分类精度好于 SVM 方法.刘大伟等利用深度信念网络对美国佐治亚州亚特兰市北部一住宅小区的分辨率影像(Resurs Dk1)的 6 种地类进行分类研究<sup>[16]</sup>.邓磊等利用深度信念网络对美国旧金山地区的 NASA/JPL AIRSAR 系统 C 波段极化 SAR 图像的 6 种地类进行分类研究,提取极化类、辐射类、空间类和子孔径类特征共 267 个作为 DBN 输入,人工均匀选取  $2 \times 10^4$  个像素点作样本,研究表明分类特征增加提高分类精<sup>[17]</sup>.李新国等则利用空间特征进行样本扩充,采用自编码器和主成分分析进行数据降维,利用 DBN 对高光谱的 Salinas 和 PaviaU 两个数据集,提高分类精度.每类地物选取约 1 000 个像素点,其中 2/3 样本用于无监督训练,1/3 样本用于有监督微调;通过非下采样轮廓波变换提取纹理特征,同时作为 DBN 的输入,提高高分辨率遥感分类精度.当隐含层数为 3,节点数为 56 时,总体精度与 Kappa 系数达到最大,分别为 81.2% 和 77.2%<sup>[18]</sup>.高鑫等提出一种基于改进的扩散平滑方法,利用图像的二阶偏导数和梯度共同控制扩散速度,并针对不同区域使用自适应扩散系数对高光谱图像进行去噪,再利用 DBN 对 Indian Pines 高光谱数据集进行分类,结果好于未去噪的 DBN 方法<sup>[19]</sup>.

#### 3.2 卷积神经网络在遥感图像处理中的应用现状

1989 年 LeCun 等提出了一种用于字符识别的卷积神经网络 LeNet-5<sup>[20]</sup>,该网络使用 7 层神经层,识别对象是 MNIST 手写字符库,识别结果达到了当时的顶尖水平<sup>[21]</sup>.曲景影等在传统 LeNet-5 网络结构的基础上,引入 ReLU 激活函数,提出了基于矩阵乘法的卷积展开技术优化模型(matrix multiple CNN,MMCNN),并应用于高分辨率遥感图像(quick bird)的 5 类对象识别.同时,探讨学习率、网络层数、各层滤波器数量和大小对分类结果影响.实验表明,学习率为 0.01,卷积层和采样层为 4,卷积核大小分别是  $21 \times 21$ 、 $17 \times 17$ 、卷积核数量 6 和 12 时效果最好,总体精度达到 91.196%,优于其他方法<sup>[22]</sup>.曹林林等把 CNN 应用于昆明城区 2007 年高分辨率遥感图像(quick bird)地表 7 种类型划分,总体精确达 98.21%<sup>[23]</sup>.陈文康把 CNN 应用于四川省丹棱县内无人机遥感影像农村建筑物识别研究发现,池化层置于归一层前面有利提高建筑物提取精度<sup>[24]</sup>.杜敬先利用最大稳定极值区域对无人机遥感影像进行影像分割得到待识别目标子区,然后采用共 7 层 CNN 模型(1 层输入层、2 层卷积层、2 层采样层、1 层全连接层、1 层输出层)对水体进行识别,识别率达到 95.36%<sup>[25]</sup>.王万国等基于 Caffee 框架实现了 Faster R-CNN 的多旋翼无人机和直升机巡检图像 3 类小型电力部件(间隔棒、防震锤、均压环)识别,准确率达 92.7%<sup>[26]</sup>,并探讨了随机失活比例、最大迭代次数、批处理尺寸、非极大值抑制前后区域保留个数对平均准确率均值影响.Liang 等结合稀疏表示理论和 CNN 对 Indian Pines 和 PaviaU 两个高光谱数据集进行研究,探讨 CNN 最优配置结构<sup>[27]</sup>.Scott 等利用迁移学习和 3 种 CNN 网络(CaffeNet、GoogleNet、ResNet50)对高分遥感数据集进行研究,取得较好研究结果<sup>[28]</sup>.为克服标签样本不足,采用数据扩充技术,主要对遥感原始图像进行水平、垂直镜像,分别对原始图像、镜像图像进行  $0^\circ$ ,  $7^\circ$ ,  $90^\circ$ ,  $97^\circ$ ,  $180^\circ$ ,  $187^\circ$ ,  $270^\circ$ ,

277°等7个方向旋转.Nogueira等采用3种训练策略(全训练、微调、特征提取方法)对6类CNN(Overfeat, AlexNet, CaffeNet, GoogleNet, VGG16, PatreNet)进行3个遥感数据集研究,研究结果表明微调是最优训练策略,并取得这3数据集最好的分类精度<sup>[29]</sup>.

在CNN演化模型应用方面,Maggiori等利用全卷积神经网络(4层卷积层、1层去卷积层)对马萨诸塞州的建筑集进行建筑与非建筑2种类型分类,训练数据340 km<sup>2</sup>、测试数据22.5 km<sup>2</sup>,从精度与计算时间指标上,均好于传统方法<sup>[30]</sup>.Fu等利用膨胀卷积(atrous convolution)、跳层结构(skip-layer structure)和条件随机场(conditional random fields)改进了全卷积神经网络,并应用于高分辨率遥感,取得较好结果<sup>[31]</sup>.但是,全卷积神经网络没有利用低层卷积层特征,对小而复杂的地物识别时效果不佳.Wang等提出门控分割网络(gated segmentation network, GSN)用于高分辨遥感图像语义分割<sup>[32]</sup>.门控分割网络包含编码器和解码器两个部份.在编码器部份,采用了残差网络(ResNet-101)作为特征提取,在解码器部份,采用了熵控制模块(entropy control module, ECM)作为特征融合.

### 3.3 自动编码器在遥感图像处理中的应用现状

林洲汉较早应用自动编码器进行高光谱数据特征提取,好于传统特征提取方法.并提出了一种基于PCA变换与像素邻域的空间信息占优的提取方法,研究表明,融合光谱特征与空间信息占优的特征所形成的空谱联合分类对分类精度改进是有效的<sup>[33]</sup>.Liu等构建了wacDAE(小波深度自动编码器)对光学遥感图像进行山崩自然灾害分类研究,该网络先进行小波变换和去噪等预处理,包含1个输入层、2层隐藏层和1层输出层,隐藏层节点数固定为100.700张遥感图像作为训练集、500张遥感图像作为测试集.实验结果表明,wacDAE有利于山崩识别<sup>[34]</sup>.阚希等利用层叠去噪自动编码器和风云三号卫星(FY-3A/VIRR)对青藏高原积雪进行识别,把10个光谱通道和4个地理信息要素作为输入层,采用三隐藏层结构(第1、2、3隐藏层单元数分别为80、10、3)和Softmax分类器对云、积雪、无雪地物进行识别,年平均精度达93.96%.研究指出根据青藏高原特征,需要进一步训练季节性的积雪判识的深度网络,以提高整体分类精度<sup>[35]</sup>.张一飞等利用栈式去噪自动编码器和高分一号遥感对湖北省蕲春县土地覆盖8种类型进行分类,在自动编码器的基础上,对训练数据随机置0方式加入噪声,增强无监督训练过程的鲁棒性,实验结果表明,当隐藏层数目为2,每层单元数为180,去噪系数为0.2时分类性能最优<sup>[36]</sup>.Wang等把主成分分析方法和导向滤波融合到自动编码器中,构建了GF-FSAE模型对高光谱数据集PaviaU和Salinas进行测试,实验结果该模型好于传统SAE和SAE-LR方法<sup>[37]</sup>.

## 4 深度学习用于遥感图像处理中存在问题与发展趋势

### 4.1 算法理论的深入研究

深度学习网络结构趋势向更深、更宽方向发展,但网络结构选取目前尚没有完善的理论依据.而网络结构是影响遥感图像分类精度的重要参数,如何找到最合适的网络结构?不同隐藏层对遥感图像特征提取的物理意义是什么?如何理解深度学习中各参数变化对分类结果影响?能否找到不同遥感数据源具备一定分类性能的网络结构?如何进一步进行遥感图像多任务问题解决,例如遥感图像描述与智能回答.这是迫切需要回答的问题.

### 4.2 典型方法的应用与修正

深度学习中典型方法在遥感领域应用有初步成果,一方面需要利用现有成果进行遥感图像处理规范建设.例如,如何均值处理、归一化、大小调整来进行遥感数据规范.另一方面,也要巩固现有成果进行技术标准化研究.如,使用修正的非线性激活函数ReLU函数解决训练速度慢;采取随机失活dropout技术和权重衰减方法防止过拟合问题;采用随机梯度下降方法解决梯度消失问题.

同时,已有的优化模型可否直接应用于不同遥感数据源处理?若是借鉴,如何修改?改哪里?新的参数如何确定?若是重新设计,新网络结构是什么?各种网络如何合作并发挥各网络功能进行智能化处理?为什么这种结构可以用?如何更好人机合作提高遥感图像处理精度与效率?

### 4.3 新模型的拓展与应用

典型方法应用仅局限于经典几个数据集研究当中,实际应用成果较少,尚未见文献报道有新的模型

应用于遥感图像处理中.如何将区域神经网络应用于遥感图像分类、定位以及相关物体检测,将有利于自然灾害监测、军事指挥等领域;如何利用递归神经网络以及长短时记忆模型的记忆功能,应用于遥感图像动态监测中,如何应用综合网络于不同遥感图像融合并提高识别精度?这些值得遥感领域学者进一步研究,拓展深度学习应用领域与研究方向.

#### 4.4 遥感大数据监测平台的建设

由于遥感数据源丰富、获取速度快、更新周期短、应用范围广、时效性强,因此,针对某一行业特点,迫切需要建立行业统一遥感大数据监测平台,将海量多源异构遥感大数据集成到该平台中.一方面,加强用于训练与测试的遥感数据集建设,侧重研究遥感数据扩充技术,例如两个对抗深度网络可以产生各式各样的样本,提高训练与测试样本量,提高泛化能力.另一方面,探索小样本甚至零样本学习问题;探索有效的可并行训练算法,减少深度学习训练时间,必定促进全球尺度遥感大数据监测.

#### 参考文献:

- [1] 何国金,王力哲,马艳,等.对地观测大数据处理:挑战与思考[J].科学通报,2015,60:470-478.
- [2] HINTON G E, SALAKHUTDINOV R R.Reducing the dimensionality of data with neural networks[J].Science, 2006,313(5786):504-507.
- [3] RICHARDS J A, JIA X P.Remote sensing digital image analysis[M].New York:Springer-Verlag,1999:229-239.
- [4] 梅安新,彭望碌,秦其明,等.遥感导论[M].北京:高等教育出版社,2006:196-201.
- [5] ETHERN Alpaydin.Introduction to machine learning[M].London:The MIT Press,2014:436-444.
- [6] 余凯,贾磊,陈雨强,等.深度学习的昨天、今天和明天[J].计算机研究与发展,2013,50(9):1799-1804.
- [7] 余滨,李绍滋,徐素霞,等.深度学习:开启大数据时代的钥匙[J].工程研究,2014,6(3):233-243.
- [8] YANN LeCun, YOSHUA Bengio, GEOFFREY Hinton.Deep learning[J].Nature,2015,521(7663):436-444.
- [9] GIRSHICK R, DONAHUE J, DARRELL T, et al.Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2014:580-587.
- [10] GIRSHICK R.R-CNN[C]//IEEE International Conference on Computer Vision,2015:1440-1448.
- [11] REN S Q, HE K M, GIRSHICK R, et al.Faster R-CNN: towards real-time object detection with region proposal networks[C]//International Conference on Computer Vision,2016.
- [12] LONG J, SHELHAMER E, DARRELL T.Fully convolutional networks for semantic segmentation[J].IEEE Conference on Computer Vision and Pattern Recognition,2015,79(10):1337-1342.
- [13] DAI J F, LI Y, HE K M, et al.R-FCN: Object detection via region-based fully convolutional networks[C]//International Conference on Computer Vision,2016.
- [14] 吕启, 窦勇, 牛新, 等.基于 DBN 模型的遥感图像分类[J].计算机研究与发展,2014,51(9):1911-1918.
- [15] CHEN Y S, ZHAO X, JIA X P.Spectral-spatial classification of hyperspectral data based on deep belief network[J].IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing,2015:1-12.
- [16] 刘大伟, 韩玲, 韩晓勇.基于深度学习的高分辨率影像分类研究[J].光学学报,2016,36(4):1-9.
- [17] 邓磊, 付姗姗, 张儒侠.深度置信网络在极化 SAR 图像分类中的应用[J].中国图象图形学报,2016,21(7):933-941.
- [18] 李新国, 黄晓晴.一种基于 DBN 的高光谱遥感图像分类方法[J].电子测量技术,2016,39(7):81-86.
- [19] 高鑫, 欧阳宁, 袁华.基于快速去噪和深度信念网络的高光谱图像分类方法[J].桂林电子科技大学学报,2016,36(6):469-476.
- [20] LECUN Y, BOSER B, DENKER J S, et al.Backpropagation applied to handwritten zip code recognition[J].Neural Computation,1989,11(4):541-551.
- [21] LECUN Y, BOTTOU L, BENGIO Y, et al.Gradient-based learning applied to document recognition[J].Proceedings of the IEEE,1998,86(11):2278-2324.
- [22] 曲景影, 孙显, 高鑫.基于 CNN 模型的高分辨率遥感图像目标识别[J].国外电子测量技术,2016,35(8):45-50.
- [23] 曹林林, 李海涛, 韩颜顺, 等.卷积神经网络在高分遥感影像分类中的应用[J].测绘科学,2016,41(9):170-175.
- [24] 陈文康.基于深度学习的农村建筑物遥感影像检测[J].测绘,2016,39(5):227-230.
- [25] 杜敬.基于深度学习的无人机遥感影像水体识别[J].江西科学,2017,35(1):158-170.

- [26] 王万国,田兵,刘越,等.基于RCNN的无人机巡检图像电力小部件识别研究[J].地球信息科学学报,2017,19(2):256-263.
- [27] LIANG H M, LI Q. Hyperspectral imagery classification using sparse representations of convolutional neural network features[J]. Remote Sensing, 2016, 9(8): 1-16.
- [28] SCOTT G J, ENGLAND M R, STARMS W A, et al. Training deep convolutional neural networks for land - cover classification of high-resolution imagery[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(4): 549-553.
- [29] NOGUEIRA K, PENATTI O A B, SANTOS J A. Towards better exploiting convolutional neural networks for remote sensing scene classification[J]. Pattern Recognition, 2017(64): 539-556.
- [30] MAGGIORI E, TARABALKA Y L Y, CHARPIAT G, et al. Fully convolutional neural networks for remote sensing image classification[C]//IEEE International Geoscience and Remote Sensing Symposium, 2016.
- [31] FU G, LIU C J, ZHOU R, et al. Classification for high resolution remote sensing using a fully convolutional neural network[J]. Remote Sensing, 2017, 9(498): 1-21.
- [32] WANG H Z, WANG Y, ZHANG Q, et al. Gated convolutional neural network for semantic segmentation in high-resolution images[J]. Remote Sensing, 2017, 9(446): 1-15.
- [33] 林洲汉.基于自动编码器的高光谱图像特征提取及分类方法研究[D].哈尔滨:哈尔滨工业大学,2014:1-48.
- [34] LIU Y, WU L Z. Geological disaster recognition on optical remote sensing images using deep learning[J]. Procedia Computer Science, 2016(91): 566-575.
- [35] 阚希,张永宏,曹庭,等.利用多光谱卫星遥感和深度学习方法进行青藏高原积雪判识[J].测绘学报,2016,45(10):1210-1221.
- [36] 张一飞,陈忠,张峰,等.基于栈式去噪自编码器的遥感图像分类[J].计算机应用,2016,36(S2):171-174.
- [37] WANG L Z, ZHANG J B, LIU P, et al. Spectral-spatial multi-feature-based deep learning for hyperspectral remote sensing image classification[J]. Soft Computing, 2017, 21: 213-221.

## Researches on Remote Sensing Images Processing Using Deep Learning Methods

LUO Xianxian<sup>1,2,3</sup>, ZENG Wei<sup>1,2,3</sup>, CHEN Xiaoyu<sup>4</sup>,  
ZHANG Dongshui<sup>5</sup>, ZHUANG Shifang<sup>1,2,3</sup>

(1. Faculty of Mathematics and Computer Science, Quanzhou Normal University, Fujian 362000, China;

2. Fujian Provincial Key Laboratory of Data Intensive Computing, Fujian 362000, China;

3. Key Laboratory of Intelligent Computing and Information Processing, Fujian Province University, Fujian 362000, China;

4. College of Resource and Environment Science, Quanzhou Normal University, Fujian 362000, China;

5. College of Resource and Environment and Safety Engineering, Hunan University of Science and Technology,  
Hunan 411201, China)

**Abstract:** Deep learning is the state-of-the-art of machine learning and artificial intelligence research, deep learning methods for remote sensing image processing have achieved rapid development. Firstly, the existing remote sensing data sources and their unsupervised and supervised classification methods are introduced. On the basis of summarizing the typical methods of deep learning and its latest evolution model, the research status of deep belief network, convolutional neural network and automatic encoder in remote sensing image processing at home and abroad are analyzed. According to the current application situation and associated issues, the development trend of deep learning's application in remote sensing image processing is discussed. On the one hand, it is necessary to strengthen theoretical research in order to adapt to the development trend of remote sensing image processing and intelligent algorithm, especially strengthening the man-machine collaboration, the application and revision of typical methods, the development and application of new model; on the other hand, according to the application requirements of remote sensing big data, it is also necessary to strengthen the construction of remote sensing data sets, and build a standard monitoring platform of remote sensing big data industry.

**Keywords:** remote sensing; deep learning; image processing

(责任编辑 韦平)